Dharmagate 架构定义

Cloudflare 数据 AI 与无 Stream 影音架构

供产品 架构 设计 工程 内容与治理团队评审
设计提案 v0.1 2026 年 10 月 25 日

01 架构定义与技术决策摘要

架构目标：用 Cloudflare 建立可追溯、可控权利、可验证答案的全球佛学资料服务。 核心资产是合法原件、版本化元数据与出处关系；搜索索引、模型和界面均应可替换。此文件面向工程、数据、安全、运维和技术采购团队，不把产品愿景写成已经实现的能力。

本版与《产品定义》和《UIUX 用户体验设计》同为 v0.1 设计提案。P0 先完成一条经核许可来源、10 至 30 部资料的文本闭环；影音为 P1，不使用 Cloudflare Stream。所有新付费服务、生产写入和资源授权都需适用审批。

决策	采用方向
资料与权利	联合目录加分权限内容库；权限在采集、派生、检索、生成、下载、撤回处共同执行。
应用与存储	Workers 承担 API 与编排；R2 保存原件派生；D1 或外部关系库保存目录与权利事实。
智能服务	混合检索与证据 RAG 优先；托管 AI Search 与自管 Vectorize 路线择优，不重复建设。
无 Stream 影音	R2 加自有播放器；FFmpeg OCR ASR 经适配器运行于已核准执行环境。
长期可迁移	原件、元数据、索引配置可导出；独立备份、恢复和撤回能力经演练确认。

Cloudflare 的产品能力、套餐、价格和地区条件按 2026 年 10 月 25 日官方资料核验。价格与容量是选型依据而非账户合同承诺；临上线需复核。中国大陆可达和当地合规是独立验证项目，不从全球网络自动推断。

02 可追溯的数据模型

以关系型目录保存事实和权限，以对象存储保存原件与派生物，以搜索索引提供查找能力。索引是可再生成的衍生物，不能成为唯一原始记录。采用内部稳定 UUID，同时保存各机构标识符；作品关系与术语映射保持显式、可审阅，不自动把相似标题认作同一作品。

实体	关键字段	设计要求
作品 Work	规范题名 异名 传统 作者 年代	年代可为区间或未知；归属存在争议时保留多观点。
表达与版本	语言 译者 校订者 版本号 底本	原文、译文与注疏分开；版本之间建立可解释关系。
数字资产 Asset	MIME 大小 SHA256 原站 存储键	原件不可覆盖；原扫描、OCR、校订文本均有独立 ID。
段落与片段	文本 边界 页码 章节 时间戳	可回到原页或播放器；引用保持稳定，不只给向量 ID。
人物与机构	名称 异名 角色 机构标识	身份由来源证明；不依据人脸或声音自动确认师者。
权利与访问	许可 权利人 地域 期限 用途	unknown 默认不允许；撤回影响所有衍生物和缓存。
处理与审阅	任务版本 模型 审阅人 错误标记	记录 OCR 与 ASR 置信度，保留人工修订和审核轨迹。

建议的字段与接口约定

书目兼容 Dublin Core 与常见馆藏标识；有条件时保留 TEI XML、IIIF manifest 及源站规范结构。对外 API 返回 canonical_id、source_url、edition_id、language、script、locator、rights、updated_at 和 provenance。系统可以映射外部格式，但不宣称在未实施校验前已完整符合任一标准。

同一片段需要三组独立版本号：内容版本、权利版本、索引版本。文本更新后重建派生；权限收紧后立即停止内容访问和检索命中，随后清除向量、缓存、摘要及离线导出授权。下载包附带许可和出处 manifest，提供校验和与版本日期，使用户拿走资料后仍知道它来自哪里。

去重不得消灭文本历史

文件层用精确校验和去重，内容层用相似度找候选，作品层由规则与人工确认。保留不同扫描、异文、译者和刊本的关系；搜索可聚合展示，却仍允许研究者逐版本查看。对简繁转换、异体字归并、巴利转写和藏文分词同时保存原串及规范化字段。

03 下载处理与发布管线

每个来源先经过权利闸门，才允许获得原件；每个派生任务再检查它自己的用途许可。推荐以 Queue 分发短任务、Workflow 管理长流程与重试；大文件与长时影音处理交给适合的容器或外部批处理，不在一次边缘请求里完成整条链。

阶段	处理结果	失败时的行为
发现与登记	来源清单 上游 ID 许可证据	授权不清留在目录层，进入人工待办。
获取与隔离	原始对象 校验和 下载凭证	限速重试；类型异常、恶意内容进入隔离区。
解析与质量	正文结构 OCR ASR 字幕时间轴	乱码或低置信度不进入正式问答库。
版本与关联	规范题名 语种 译本 版本关系	模糊匹配只生成候选，不静默合并作品。
派生与索引	词法索引 向量 缩略图 可下载包	按许可执行；索引可重建，原件不可修改。
审阅与发布	审核签名 引文定位 公开版本	来源或权利缺失则阻断发布。
同步与撤回	增量变更 删除与缓存清除记录	停止服务优先，彻底清理随后可核查完成。

工程上必须具备的控制

任务幂等键由来源 ID、资源 ID、内容版本与任务类型组成；消息重复投递不得重复收费或制造重复资产。保留检查点、死信队列和失败原因，人工可以单项重放。下载和 OCR、ASR、嵌入分别设每日额度，防止抓取异常带来无界成本。对上游删除或许可变化，先触发内容下线事件，再处理衍生物清理。

OCR 不能只看整页平均置信度。分别抽查典籍编号、专名、偈颂、页码和校勘符号；传统文字、竖排、手稿需要专门模型与校对。ASR 应按语种和录音环境评测，保存说话人标识为未验证或由人工确认，不推测身份、种族、宗教归属或心理状态。

第一期的安全边界

P0 只处理一条来源的 10 至 30 部代表资料，先完成端到端验证。后续批量范围经权利和预算批准再扩展。每批以权利信息完整率 100% 为发布条件；低质量材料可以作为带警示的目录存在，但不能冒充已校勘正文进入权威问答。

04 Cloudflare 参考架构

Cloudflare 承担全球接入与主要应用控制面；合法内容是资产，检索与模型是可替换的服务。建议把业务域拆成 public、catalog、ingest、search、ai、review 和 admin，避免一个 Worker 同时拥有全部下载、管理与删除权限。

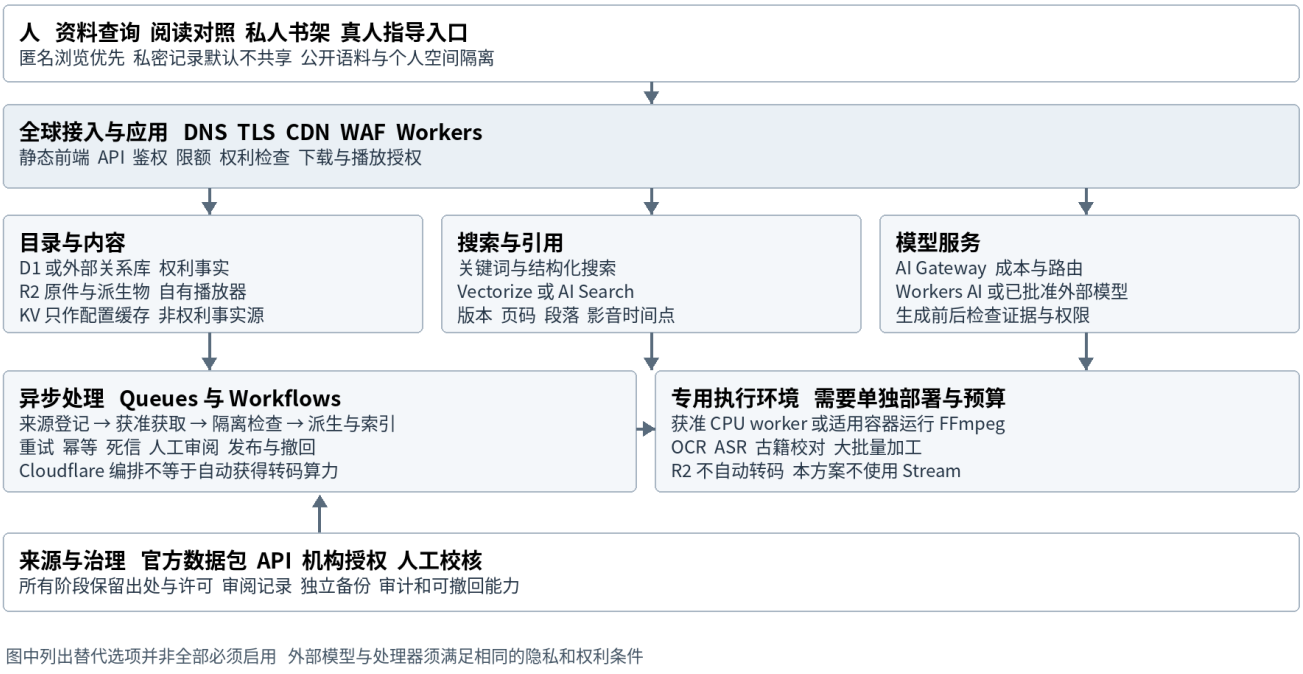


图 1 参考架构 箭头表示数据或调用关系 权利检查横跨采集 检索 生成 下载和删除

在线请求路径

浏览器通过 DNS、TLS、缓存与 WAF 到达静态站点和 Workers API。目录查询先查结构化字段及词法索引；语义检索再访问 Vectorize 或托管检索能力。模型请求经 AI Gateway 统一做限额、可观测与路由。返回前验证证据、权限和引用定位；下载则由服务签发短期授权地址，不公开暴露私有对象。

离线处理路径

经批准的来源进入采集队列，Workflows 协调获取、检测、提取、校对、索引和发布。R2 分开放置隔离原件、已批准内容与衍生物；目录及权利事实在 D1 或外部关系数据库中维护。需要 PostgreSQL 和更复杂事务时，通过 Hyperdrive 连接受管理数据库，而不是误把 Hyperdrive 当数据库。

业务日志、模型使用量和内容质量分别观测。私密修学记录不与公共语料共库索引，不进入默认日志或模型训练。部署、回滚、备份恢复和删除验证均用独立环境演练。中国大陆访问与当地合规另立项目验证，不从‘全球网络’推断大陆一定可用或已满足数据要求。

05 产品选择与能力边界

‘使用所有已有能力’应落实为：充分利用合适的 Cloudflare 能力，并解释未采用的原因。产品、套餐与可用地区会变化，下表是选择框架，不是采购承诺。托管 AI 检索与自建检索是可以替换或组合的路径，不应一开始维护两套重复成本。

档位	能力	使用位置与注意事项
必选	DNS TLS CDN WAF	公开入口与应用保护；缓存不能越过用户与内容权限。
必选	Workers 静态资源	前端、API、鉴权和请求编排；不执行长时重型批处理。
必选	R2 Queues Workflows	内容存储与异步管线；为重试、吞吐、对象大小和保留期设预算。
必选	D1 或外部关系库	目录和权利事实；以真实规模、事务和地区需求选择。
必选	AI Gateway 与观测	模型访问、限额、成本和错误追踪；默认避免记录敏感正文。
按需	Workers AI Vectorize AI Search	嵌入、推理与检索。先验证语种、权利过滤和引用保真度。
按需	Images 与自有播放器	Images 可用于授权图像；影音采用 R2 加自有播放器，转码算力另配。本方案不使用 Stream。
按需	Durable Objects KV	协作会话和轻量配置；KV 不承担强一致的权限事实源。
按需	Access Turnstile Gateway	后台访问、反滥用与团队出口保护；不把人机挑战当完整安全体系。
按需	Containers Hyperdrive 浏览器渲染	重型适配器、外部数据库连接、获准的动态页处理。
暂缓	Realtime 大规模直播 Agent 自主执行	先证明需求；不让智能体自由抓取、发布或改变授权。
暂缓	训练专用模型与全域数据平台	先积累评测与治理能力；训练不是获得知识可靠性的捷径。

不要假设 Cloudflare 原生产品已覆盖所有需求：多语言全文搜索、复杂知识图谱、专业古籍 OCR、档案级保存、长时音视频处理及严格数据驻留，可能需要外部组件或合作机构。保持开放接口和可导出的原件、元数据、索引配置，避免把长期文化资产锁在某一种模型或产品里。

产品边界的核验依据见 [C1][C3][C10] 至 [C19]。Browser Run 只用于获准动态页；图片处理应核单图限制，古籍超大扫描优先切片和缩略图。[C20][C21]

06 容量限制与选型验证

这些限制直接影响设计，不能只在采购时才发现。数值按 2026 年 10 月 25 日读取的官方资料；上线前再次确认套餐和当前限制。首期应制作小型容量实验，测量真实文本、向量、影音和权限过滤行为。

产品	当前重要边界	架构含义
Workers	128 MB 内存；付费 HTTP CPU 默认 30 秒，最高 5 分钟。[C1]	边缘服务专注鉴权和编排，不承担整部视频转码。
AI Search	付费单实例最多 100 万文件，混合索引 50 万；自定义元数据仅 5 字段。[C10]	独立保存书目与权利事实。采用前验证细粒度权限，不把它当完整档案库。
AI Search 文件	OCR PDF 及文本上限 10 MiB；非 OCR PDF 与其他格式 4 MiB。[C10]	大扫描册先由专用管线处理，按稳定段落和页码组织，不任意截断证据。
Vectorize	每索引最多 2000 万向量、1536 维；10 个元数据索引。[C11]	选嵌入模型前核维度；维度或距离算法更换需新建索引并重建切换。
D1	付费单库 10 GB，账户 1 TB；行最大 2 MB。[C12]	存目录和作业元数据，不塞影音与整库 OCR；增长时分域或采用外部关系库。
KV	最终一致；跨区域变更可能 60 秒或更久。[C13]	不作即时撤权的唯一真源；命中缓存后仍需权威访问判断。
Queues	至少一次投递，消息最大 128 KB。[C14][C23]	消息传对象指针与任务 ID；幂等、去重、死信与重放必需。
Workflows	耐久编排不等于无限 CPU；完成记录有保留期限。[C15]	长期审计另存；OCR 和转码运行在专用执行器。

AI Gateway 提供观测、缓存、限额和模型路由，不负责自动证明事实。Workers AI 的多语模型能力也不能代替对古汉语、巴利语、梵语和藏语的实测。Hyperdrive 只是外部 PostgreSQL 或 MySQL 的连接优化，不是数据库托管服务。[C16][C17][C18]

本版不假设 Cloudflare 提供任意 GPU 训练或档案级长期保存的完整交钥匙服务。专业 OCR、罕见语种 ASR、知识图谱和超长批处理保留可替换适配器；容器可选，但必须先确认产品限制、算力与预算。[C19]

07 无 Stream 影音工程设计

R2 是对象存储，不是自动媒体加工平台。 影音 P1 的首个版本使用 H.264 与 AAC 的 faststart MP4、独立音频、WebVTT 字幕和海报；达到弱网需求与规模门槛后，再增加 2 至 3 档预生成 HLS。DASH、DRM 与直播暂不纳入。转码、抽音轨、字幕和码率梯度由获准 CPU 执行器完成，Workflows 只负责协调。[C1] [C3]

工作面	必须实现的细节
资产和发布	原件 私有待审 公开派生分离。键含 asset_id/version/profile/hash；对象不可变，manifest 最后发布，记录 ffprobe 与 FFmpeg 版本。
公开点播	使用自定义域和缓存规则；r2.dev 仅开发，不作为正式播放域。巨型 MP4 的可缓存性受套餐上限影响，短 HLS 分片更稳妥。[C4][C5]
私有点播	Worker 验证 session 或短期签名的资产、版本、路径和到期时间；manifest、分片、字幕、海报均受同等授权。鉴权必须先于共享缓存。
简单下载	可使用短期 S3 presigned URL，但它是可重用 bearer token；只适用指定 R2 API 域名，不能直接当自定义域 CDN 签名。[C6]
HTTP 正确性	完整测试 GET HEAD 200 206 304 416、Content Range、长度、ETag 与 Range；If Range 由应用层策略处理，禁止部分 body 错返 200。[C7]
缓存与跨域	Cache API 不接受 put 206，且为本地数据中心缓存；完整分片 200 缓存更简单。CORS 只允许所需站点与头部，不能替代鉴权。[C8][C9]
撤回与恢复	撤回后令牌拒绝、目录下架、公开派生封禁与缓存清除、字幕及向量删除；从原件与版本化配置可以重建派生。

Workers 单 isolate 内存为 128 MB；付费 HTTP CPU 默认 30 秒、可提高到 5 分钟，因此不能将长视频 FFmpeg 转码塞进请求。长连接不等于无限 CPU。CPU 环境尚未确认时，转码执行任务标为 Blocked，不能擅自新增付费服务。[C1]

签名链接、HLS 加密或隐藏对象地址都不是完整 DRM，不能承诺防录屏和防复制。浏览器与真实设备必须测试播放、seek、倍速、字幕、弱网和授权续期；‘页面打开了’不等于媒体验收完成。

08 搜索与证据型问答

先让人找到可靠材料 再让模型帮助理解

统一搜索需要四种入口：精确书目和典籍编号、全文关键词、概念与跨语义检索、影音时间片检索。搜索结果明确区分原典、译文、注疏、讲授、学术研究与 AI 生成解释。用户可按传统、语种、年代、版本、媒介、来源、权利和审阅状态过滤；同一段的多译本并列，而非模型融合成没有出处的新文本。

步骤	实现要求
理解问题	判断用户是在找书、比较译本、寻求解释还是个人实践；只在必要时追问传统和经验。
检索前鉴权	先按用户、地区、用途及来源权利建立可见范围，再进行检索；不把受限片段交给模型后再遮掩。
混合召回	典籍编号和关键词优先精确命中；结合语义向量，原文与规范化字段并行保留。
重排与证据束	选择相互独立的高质量来源；保留版本、段落、页码或时间点，不只返回摘要。
受约束生成	仅凭证据回答事实问题，区别引文、释义与推测；存在传统差异时列出，不擅自判定唯一正确。
引用校验	检查引用确实包含所述内容、链接可开、定位准确；证据不足则诚实说明并给出检索入口。
审计与反馈	保存非敏感的证据 ID 和模型版本；允许报告错引，能撤回有问题的答案。

防止看似有引用 实际无证据

答案中的每一项重要事实应有证据支持，引用卡片展开后直接看到原段与上下文。经文不得由模型凭记忆补全；找不到就明确说找不到。模型不能把检索结果里的指令当系统指令，不能因为网页写着‘忽略规则’就访问秘密或改变工具行为。生成前后的权限验证和证据校验由代码与规则实施，不能只靠提示词。

初期保持 RAG 与模型训练分开：得到检索使用许可并不自动得到微调许可。引用呈现也应遵循原文许可和合理使用范围；不能用问答接口连续拼接受限书籍全文。设置输出长度、频率和跨请求聚合检测，同时保留公开允许下载的正常渠道。

跨语检索保留原始查询与文本；简繁、异体字、巴利变音符、梵文书写系统与藏文分词分别处理。机器翻译不替代正式译本；每种语言与年代独立评测，不把通用模型的多语宣称当佛学准确率。

09 数据接口与授权契约

以下为建议 API 契约，不是已存在端点。API 使用版本前缀，返回稳定 ID 和可机器读取的状态；所有写操作和有成本任务都需要明确主体、用途与审计事件。授权决定由服务端执行，不依赖前端隐藏按钮。

接口	核心输入和输出	权限与行为
GET /v1/works	题名 编号 语言 版本 来源；分页返回书目	仅返回可见元数据；不能把全文伪装成列表字段。
GET /v1/assets/{id}	版本 locator rights provenance	同一资产的原件、OCR、修订与派生有不同 ID。
POST /v1/search	query filters language cursor	先确定权限范围；返回段落与页码或时间点。
POST /v1/answers	问题 可选语境 evidence_ids	回答含 claims 引文 source_id locator；无证据返回不足状态。
POST /v1/downloads	asset_id version intended_use	短期授权范围明确；不泄露私有存储凭据。
POST /v1/corrections	segment_id 问题 修订建议	记录提交与审阅状态；不直接覆盖已发布文本。
POST /v1/ingest/jobs	source_id manifest version	后台批准来源才能调用；幂等键防止重复加工。
POST /v1/revocations	asset_id rights_version reason	即时阻断访问，异步清理所有衍生并核查回执。

一致性和事件

目录、权利和发布状态以关系型事实库为准。事件包含 event_id、asset_id、content_version、rights_version、event_type、occurred_at 和 actor_id，消费者幂等处理。定义 staged、processing、review_required、published、restricted、revoked、failed 等状态；撤回优先级高于正在运行的发布任务。

向量和答案缓存标记内容与权利版本；索引落后时可降级为目录或原文查询，不继续展示旧权限结果。相同幂等键重复请求应返回同一作业，不重复计费。长期审计存放于业务存储，而不是依赖队列或工作流的有限运行历史。

错误状态至少区分未授权、权限已撤回、资料尚在处理、证据不足、额度耗尽和服务不可用。客户端可重试与不可重试错误分开；不对外暴露密钥、内部对象路径或未经授权的资源是否存在。

10 隐私安全与全球运营

把宗教与修学信息作为敏感数据设计

默认允许匿名检索与阅读。个人信仰、困扰、日记、课程关系与私人书架采用最少采集原则，公开资料库与私有空间逻辑及权限隔离。私人内容默认不用于训练、不进入公共向量库、不进入面向运营人员的明文日志；向外部模型发送前明确提示并给予控制，尽量减少上下文。

风险面	必须的控制与证据
后台与密钥	Access 或同等身份验证、MFA、短期凭据、最小权限、环境分离与密钥轮换。
对象与下载	私有桶、签名访问、权限版本校验、防越权测试；禁止把可缓存响应混入私人内容。
采集与上传	域名白名单、SSRF 防护、文件类型验证、恶意文件扫描、隔离和资源配额。
模型与检索	不可信文档隔离、工具白名单、引用验证、提示注入测试和受限资源防拼接。
日志与监控	去标识化事件、敏感字段遮盖、短期保留、分角色访问与可追查的安全审计。
删除与撤回	内容、向量、缓存、摘要和下载入口联动；备份按政策到期清除并记录例外。
灾备与退出	独立备份、导出格式、校验和清单、恢复演练与供应商迁移手册。

全球网络不自动解决数据驻留与本地合规

各地访问速度、内容许可、隐私法律与跨境处理要求可能不同。地区策略应明确哪些内容可展示、哪些个人数据可存储和调用模型，以及访问失败时的说明。Cloudflare 全球产品、区域化能力和中国网络是不同事项；中国大陆访问、域名备案、服务条件与数据处理须单独与服务商及专业顾问核实，不能承诺全球同等可达。 官方 China Network 是 Enterprise 独立订阅、与 JD Cloud 合作，并非全部全球产品自动可用。[C22]

可靠性与发布纪律

建议先设公开目录月度可用性 99.9% 的服务目标，再用压测与运行数据校准；AI 失败时仍能检索并阅读原文。所有变更通过开发、预生产、生产环境，采用灰度和可回滚配置。目录备份恢复目标、内容复制周期与事故联系人必须写入运行手册，未经恢复演练不宣布具备灾备。

既有网站先保持稳定。新架构使用独立预生产域名进行功能、安全和重定向测试；切换前保存旧版本、明确回退触发条件，尤其验证首页路由优先级、缓存和健康检查。正式切换属于新的执行决策，本方案本身不授权改动线上系统。

11 部署方案与架构决策记录

先保护旧站 再发布新能力

先只读记录生产基线和旧应用契约，在隔离环境复用已有成果。开发、预生产、生产分离账号或最少分离资源与凭据；示例配置只含占位符，不包含真实账户绑定、令牌、数据导出或本地数据库。不得把本地演练配置直接覆盖生产。

发布关口	应保留的证据
基线与兼容	当前真实版本、已登记路由和接口、绑定类别、未知项；旧应用导航与登录回调测试。
候选包审阅	代码差异、依赖锁定、配置检查、禁止秘密与未知绑定变化；数据库迁移独立评审。
预生产验证	真实请求、权限矩阵、引用、媒体字节与设备测试；故障和成本降级演练。
灰度与切换	有限流量或明确人群；监测错误、延迟、权限失败和源站负载；阈值触发回退。
回退与恢复	保存前版与配置版本；明确代码回退不恢复业务数据，数据恢复单独演练。
上线后验收	新首页与旧应用分别验证；不是 CI 成功即业务通过，保留审阅和用户任务记录。

关键架构决策

ADR 001：联合目录与合法镜像并存，避免把授权缺口藏在技术抓取后。ADR 002：RAG 优先、训练默认关闭，便于保留证据及撤回。ADR 003：AI Search 与自管检索以样本比较选择；需要更强版本对齐或权限结构时优先可控方案。ADR 004：无 Stream 点播，把转码和播放器质量责任显式列入 backlog。

ADR 005：D1 或外部关系库保存权利事实，KV 不作即时撤权唯一来源。ADR 006：公开语料与私人修学记录隔离；个性化不默认进入共享模型。ADR 007：独立备份与可导出优先，防止文化资料被单一服务绑定。每条 ADR 都记录选择原因、被拒方案、评估数据和重新考虑触发条件。

从试点到规模化

扩容先看授权、处理成功率、检索质量和单位成本，再增加来源或容量；不要同时扩大语种、载体和并发。对新语种、新模型和新转码 profile，先建立独立评测与可回滚版本，再切换服务。即时任务队列和大规模离线重建要隔离，防止一次全库重索引挤占用户请求。

12 成本模型与预算控制

下表是规划口径，不是实际账单或报价。总成本包括云服务、数据处理、授权、人工校勘与持续运营；对古籍和多语影音，人工质量与权利协调可能比存储更重要。Cloudflare 价格须在采购时复核，税费、企业协议、免费额度与地区条件另计。[C3]

成本项	计量方法	需要设定的假设
对象存储	平均 GB 月 × 存储单价，加读写请求	原件 派生物 副本 版本保留与增长。
视频	R2 体积与读写请求，加播放网关和转码	原件与码率派生比、播放小时、分片时长、缓存命中。
计算与工作流	请求 CPU 时间 队列操作与执行	API 峰值、后台批次、重试倍数和超限行为。
搜索与索引	索引规模 更新量 查询量	段落数、向量维度、多语重复索引、重建频率。
AI 推理	输入输出量或模型计费单位	问答数、上下文长度、缓存率、模型路由。
一次性加工	页数或分钟数 × OCR ASR 翻译单价	原始质量、语言、复核比例及失败重做。
人工与许可	人员月、合作费和审阅工时	每千页校勘工时、权利协调与教师治理。

三档规模假设

档位	可计费对象规模示例	明确边界
90 天试点	首个闭环 10 至 30 部资料；1 TB 仅为容量预算情景；每月 1 万次 AI 为压力估算	不是必须存满，也不是已发生用量。
成长阶段	10 TB R2；多语索引；每月 10 万次 AI 问答；视频独立估算	须经授权量、运维人员及预算门槛批准。
全球协作	100 TB 起的保存规模与多个机构节点	先做容量和成本实测，不按试点简单线性承诺。

预算护栏建议： 为下载、OCR、ASR、嵌入、推理和播放分别设置月度上限与告警。到 50% 检查趋势，到 80% 调低非必要批处理，到 100% 暂停新增高成本任务而保留目录和阅读。任何自动降级都不得改用不满足隐私或许可条件的模型。

成本仪表盘至少展示每千个新文献的加工费、每千次成功搜索的费用、每个有证据答案的费用、每小时影音的加工与服务费，以及人工复核工时。发布前用真实样本测量；不要凭单个模型演示推断全年预算。

13 成本示例与扩容门槛

R2 Standard 存储示例： 当前公开单价为每 GB 月 0.015 美元，Class A 每百万次 4.50 美元，Class B 每百万次 0.36 美元，直接 R2 出站流量免费。按十进制 1 TB 等于 1000 GB，1 TB、10 TB、100 TB 仅存储约为每月 15、150、1500 美元；100 TB 原件加 50 TB 派生约为 2250 美元。未扣免费额度，未含请求、计算、AI、人工和税费。[C3]

6 秒 HLS 分片每播放小时约有 600 个视频分片请求，独立音轨再约 600 个。每月 10 万播放小时可能产生 6000 万至 1.2 亿分片请求，另有清单、字幕与重试；缓存可减少 R2 读取，却未必减少每次 Worker 鉴权。故‘免费出站’不等于免费影音平台。IA 的读取费用和访问模式另算，不作为热播放默认。[C3]

十进制容量示例	R2 Standard 存储月费	不是总预算
1 TB	约 15 美元	未含请求、计算、AI、人工、许可、税费。
10 TB	约 150 美元	同上，派生文件和副本另计。
100 TB	约 1500 美元	同上，不能据此承诺全球资料预算。
100 TB 原件加 50 TB 派生	约 2250 美元	未扣免费额度，不含额外独立备份。

近期价格变更需单独纳入预算

AI Search 官方页在本轮核验时说明 2026 年 11 月 1 日起按新口径收费。示例超额费为摄取每百万 token 0.75 美元、OCR 图像摄取再加每百万 token 0.50 美元、存储每 GB 月 2 美元、语义或混合检索每千次 0.75 美元、全文检索每千次 0.10 美元。重叠切片重复计 token，生成与查询改写另计；其内含嵌入、重排及向量服务不能再重复作为独立成本累计。应以启用当日页面及合同为准。[C10]

用真实样本决定是否扩容

先对每个代表来源抽 10 至 20 件资料，测量每千页字节量、OCR 时间、有效段落数、嵌入 token、人工修订时间与引用错误率；影音至少包含短音频、长视频和损坏文件。推理按问题长度、证据上下文和输出长度分组测量，得到每个成功任务的费用分布，而不是只取平均。

扩容审批应同时看到授权覆盖、质量达标率、预计三个月增长和最坏重试费用。可以先扩目录和已授权文本，再扩高质量影音；不得因存储便宜就跳过人工审阅或无边界地建立昂贵衍生索引。未明确 CPU 执行器前，媒体转码保留为阻塞项，不为推进计划偷偷开通服务。

14 Cloudflare 官方核验来源 1

核验日期为 2026 年 10 月 25 日。能力和价格会变化，实施时重新确认套餐与账户合同。正文中 [C 编号] 对应以下可点击官方来源。

[C1] Workers 运行限制

[C2] R2 对象与上传限制

[C3] R2 价格

[C4] R2 公开桶和自定义域

[C5] 缓存默认行为与对象上限

[C6] R2 S3 预签名地址

[C7] R2 Workers API 与条件 Range 访问

[C8] Workers Cache API

[C9] R2 跨域配置

[C10] AI Search 限制与价格

[C11] Vectorize 限制

[C12] D1 限制与恢复窗口

15 Cloudflare 官方核验来源 2

核验日期为 2026 年 10 月 25 日。能力和价格会变化，实施时重新确认套餐与账户合同。正文中 [C 编号] 对应以下可点击官方来源。

[C13] Workers KV 一致性说明

[C14] Queues 投递保证

[C15] Workflows 限制

[C16] AI Gateway 能力

[C17] Workers AI 模型目录

[C18] Hyperdrive 定位与能力

[C19] Containers 限制

[C20] Browser Run

[C21] Images 限制

[C22] China Network 条件与定位

[C23] Queues 容量与消息限制